



Inteligência Artificial
Prof. Luiz Antonio Ferraro Mathias

Aprendizagem

O aprendizado pode ser definido como: o ato ou efeito de aprender um ofício, uma arte ou ciência; o tempo despendido nesse processo de aquisição de conhecimentos; o exercício ou desempenho inicial do que se aprendeu; a denominação comum a mudanças permanentes de comportamento em decorrência de treino ou experiência anterior (MICHAELIS, 2020).

Dessa maneira é possível observar que o processo de aprendizado está intimamente relacionado com a influência de conhecimentos e novas observações que serão encarregados de tornar possível a execução de novos conhecimentos.

Essas influências estão associadas a métodos de inferência lógica. Tais métodos de influência lógica, poderão ser acoplados em três classes distintas, sendo elas a dedução, indução e abdução (PRATI, 2006).

Na dedução, a conclusão é obtida através de dados e informações já existentes, obtendo dessa forma um conhecimento verdadeiro. De modo geral, esse tipo de aprendizagem engloba qualquer conhecimento adquirido, sendo resultante de transformações sobre um conhecimento já existente, mantendo assim a verdade.

Aprendizagem

No aprendizado por indução é definido como **uma forma de raciocínio que tem como origem um conceito particular e generalizado**, devido o aprendizado por indução permitir sobre-exceder as premissas obtendo conclusões genéricas originadas de exemplos específicos. Dessa maneira a indução procede da parte para o todo, do particular para o universal.

No aprendizado **por abdução o objetivo é deduzir um conhecimento específico por meio de observações e informações já conhecidas**. Algumas inferências de aprendizagem por abdução são criadas a partir de um grupo de predicados particulares não observados. Diante disso esses tipos de inferências utilizam conhecimentos incompletos além de agregar conhecimentos sobre um caso específico acerca de determinado assunto.



Aprendizagem

Um processo de aprendizagem inclui a aquisição de novas formas de conhecimento: o desenvolvimento motor e a habilidade cognitiva (através de instruções ou prática), a organização do novo conhecimento (representações efetivas) e as descobertas de novos fatos e teorias através da observação e experimentação. Desde o início da era dos computadores, tem sido realizadas pesquisas para implantar algumas destas capacidades em computadores.



Aprendizado indutivo

O objetivo do aprendizado indutivo é encontrar uma hipótese (h) que concorde com um conjunto de exemplos.

Uma hipótese é considerada satisfatória quando possui uma boa capacidade de generalização.

Exemplo 1: detecção de bons clientes para um cartão de crédito.

- a) Tarefa (T): classificar potenciais novos clientes como bons ou maus pagadores;
- b) Medida de Desempenho (P): porcentagem de clientes classificados corretamente;
- c) Experiência de Treinamento (E): uma base de dados histórica em que os clientes já conhecidos são previamente classificados como bons ou maus pagadores.



Aprendizado indutivo

Exemplo 2: diagnóstico de gravidez de risco

- a) Tarefa (T): classificar novas gestantes com potenciais riscos na gravidez;
- b) Medida de Desempenho (P): porcentagem de pacientes classificadas corretamente;
- c) Experiência de Treinamento (E): base de dados histórica contendo exemplos de gestantes com ou sem gravidez de risco.



Aprendizado de máquina

As técnicas que utilizavam a IA solucionavam um encadeamento de problemas práticos utilizando para isso um conhecimento de determinado âmbito como, por exemplo, o campo de medicina sendo possível criar inferências por meio de regras, descobertas de diagnósticos e detecção de infecções. Os sistemas desenvolvidos para tal finalidade ficaram denominados de Sistemas Especialistas ou então de Sistemas Baseados em Conhecimento.

Para que esses sistemas fossem capazes de exercer sua função, era necessário a aquisição do conhecimento de um especialista do ramo. O processo realizado para isso era submetido a falta de cooperação, intuição do especialista, informações instáveis, entre outros fatores críticos para formar as características das informações apuradas.



Aprendizado de máquina

Com o progresso da utilização desses sistemas, os problemas tornaram – se mais complexos além da existência de uma grande quantidade de dados. Diante dessa situação tornou – se inevitável a criação de sistemas mais sofisticados que fossem capazes de resolver problemas sem necessitar de intervenções humanas. Os sistemas cobiçados para essas funções deveriam possuir como base para isso as experiências ocorridas anteriormente e construir inferências, para assim serem capazes de resolverem determinados problemas.

A técnica para a obtenção de conclusões genéricas com base em um agrupamento de exemplos é denominada de indução, que é um processo de inferência lógica, assim como detalhado anteriormente.



Aprendizado de máquina

O Aprendizado de Máquina (AM) - do inglês, *Machine Learning* - é um subcampo da área de Inteligência Artificial, tem como intuito de criar sistemas que a partir do fornecimento de dados sejam capazes de tornar os mesmos aptos a aprender (PRATI, 2006 apud MONARD, 2003). O AM utiliza de algoritmos que são habilitados a executar a tomada de decisões. Dessa maneira, o AM irá desenvolver sistemas que serão treinados a partir do emprego de um grande volume de dados. Estes sistemas também são responsáveis por prever resultados, tendências e padrões de forma que, **quanto maior for o volume de dados mais preciso os algoritmos** (BARNES, 2015).

O aprendizado é adquirido através de experiências, que através do progresso das tarefas, o sistema aprende a melhor forma de resolver os problemas (SILVA, 2005 apud SANTOS, 2005 apud MITCHELL, 1997). Dessa forma o Aprendizado de Máquina é definido como “Diz – se que um programa de computador aprende a partir da experiência E com respeito a algumas classes de tarefas T e uma dada medida de desempenho P se o seu desempenho nas tarefas T, medidas por P, melhorarem com a experiência E.” (SILVA, 2005 apud MITCHELL, 1997, p. 2).



Características gerais do Aprendizado de máquina

As técnicas que utilizavam a IA solucionavam um encadeamento de problemas práticos utilizando para isso um conhecimento de determinado âmbito como, por exemplo, o campo de medicina sendo possível criar inferências por meio de regras, descobertas de diagnósticos e detecção de infecções. Os sistemas desenvolvidos para tal finalidade ficaram denominados de Sistemas Especialistas ou então de Sistemas Baseados em Conhecimento.

Os sistemas de Machine Learning possuem características próprias que permitem uma classificação não exclusiva deles em função da linguagem de descrição, tipo de aprendizado, paradigma de aprendizado, formas e tarefas de aprendizado (PRATI, 2006).

A tabela a seguir exibe de forma resumida as características de um sistema de AM:



Características gerais do Aprendizado de máquina

Tipos de Aprendizado	Técnicas	Paradigmas	Linguagens de Descrição	Formas de Aprendizado	Tarefas de Aprendizado
Supervisionado	K-NN	Simbólico	Lógica de Ordem Zero	Incremental	Classificação
Não Supervisionado	Redes Neurais Artificiais	Conexionista	Lógica de Atributos	Não Incremental	Regressão
Semi-Supervisionado	Árvores de Decisão	Estatístico	Lógica de Primeira Ordem		Ordenação
Por Reforço	Naive Bayes	Genético			
		Baseado em Exemplos			



Tipos de Aprendizado de máquina

Em relação ao modo como os algoritmos aprendem, os sistemas de Machine Learning são divididos em: supervisionado, não supervisionado, semi-supervisionado e por reforço (PRATI, 2006).

No aprendizado supervisionado o sistema irá receber um conjunto de dados rotulados, onde cada um desses dados é representado por um conjunto de atributos e pelo valor da classe à qual o dado pertence. O aprendizado supervisionado tem como objetivo classificar de maneira correta a classe de novos dados que ainda não foram rotulados.

No aprendizado não supervisionado, por outro lado, os algoritmos não conhecem a classe à qual o conjunto de dados estão relacionados, com isso o sistema tenta classificar esses conjuntos agrupando os semelhantes em determinadas classes. Esse agrupamento também é conhecido como Clusterização – do inglês, Clustering – um processo que otimizará os dados tornando os resultados da classificação mais eficiente. Após a realização dos agrupamentos, é realizada uma análise para determinar o significado de cada cluster na situação do problema sendo analisado.



Tipos de Aprendizado de máquina

O aprendizado semi-supervisionado se baseia entre o aprendizado supervisionado e o aprendizado não supervisionado. Nesse aprendizado são utilizados dados rotulados e não rotulados. A técnica é utilizada, normalmente, em situações em que os conjuntos de dados rotulados são difíceis de serem adquiridos, enquanto os dados não rotulados estão presentes de forma abundante no conjunto e são facilmente apurados. Dessa forma, o objetivo desse aprendizado é classificar os dados obtidos para a criação de melhores classificadores.



Paradigmas de Aprendizado de máquina

A representação do conhecimento é obtida a partir de dados, podendo ser feita de várias maneiras, a partir de técnicas de aprendizado de máquina, como K - Vizinhos mais Próximos, Redes Neurais Artificiais, Árvores de Decisão ou pelo Naive Bayes, como visto na seção anterior (PRATI, 2006).

Essas distintas formas de representação do conhecimento são provenientes dos paradigmas de aprendizado. Nesta seção são detalhados alguns destes, tais como o paradigma simbólico, conexionista, evolucionista, estatístico e baseado em exemplos.

O paradigma simbólico o processo de aprendizado de máquina se dá através de representações simbólicas, ou seja, por meio de números, letras, palavras e símbolos e expressa o seu aprendizado através de algoritmos de AM, como por exemplo, expressões lógicas, árvores de decisão, regras de produção ou redes semânticas.



Paradigmas de Aprendizado de máquina

O paradigma conexionista tem como principal representante as RNA's, que são esquemas matemáticos para representar o funcionamento do neurônio biológico como visto no tópico anterior. Tal paradigma recebe o nome de conexionismo pelo fato de os sistemas funcionarem através de unidades neurais interconectadas.

A ideia principal do paradigma estatístico baseia-se em utilizar modelos estatísticos a fim de buscar possibilidade de ter uma aproximação do conceito de ser induzido. Grande parte desses modelos são paramétricos e para isso apresentam-se de modelos pré-estabelecidos, de modo que os valores são ajustados para os parâmetros do modelo a partir dos dados.



Paradigmas de Aprendizado de máquina

O paradigma genético é proveniente do paradigma evolucionista de aprendizagem. Esse paradigma utiliza como analogia a teoria darwinista ou teoria da seleção natural que estabelece que **as espécies mais adaptadas ao meio têm mais chances de sobreviver do que as espécies menos adaptadas**, enquanto no modelo genético de aprendizado, um conjunto de exemplos disputam entre si para fazer um prognóstico de novos exemplos, no qual os elementos que possuem menor desempenho são desprezados, à medida que os mais fortes se proliferam (PRATI, 2006 apud HOLLAND, 1975).

O paradigma baseado em exemplos tem como conceito classificar casos desconhecidos, tendo como base para isso os casos similares já classificados anteriormente no qual as classes são conhecidas. Um exemplo de técnica de aprendizado de máquina que utiliza esse paradigma são os K-vizinhos mais próximos (K-NN), onde **o sistema irá armazenar todos os exemplos de treinamentos e a classificação será composta pela maior quantidade de exemplos vizinhos de uma determinada classe.**



Aprendizado profundo de máquina

O Aprendizado Profundo de Máquina ou *Deep Learning* “[...] é uma subárea de Aprendizagem de Máquina que investiga técnicas para simular o comportamento do cérebro humano em tarefas como reconhecimento visual, reconhecimento de fala e processamento de linguagem natural.” (BEZERRA, 2016, p. 30). Em outras palavras, criar uma máquina que possa “fingir” e se passar por qualquer ser humano, não importa a nacionalidade, sem ser percebida como tal.

“O Aprendizado Profundo permite que modelos computacionais compostos por várias camadas de processamento aprendam representações de dados com vários níveis de abstração.” (LECUN et al., 2015). O objetivo é fazer com que a máquina reconheça e separe os dados e aloque-os de acordo com a sua similaridade, assim percebendo variações que os seres humanos demorariam para perceber, fazendo uso do algoritmo de retropropagação (LECUN et al., 2015 apud RUMELHART; HINTON; WILLIAMS, 1986) para treinamento das redes, afim de indicar como uma máquina deve alterar seus parâmetros usando a representação em cada camada a partir da representação na camada anterior, para assim realizar seus cálculos (LECUN et al., 2015).



Aprendizado profundo de máquina

O Aprendizado Profundo de Máquina é muito utilizado em diversas aplicações como o Google Translate ou Tradutor, para o reconhecimento e tradução de textos, pelos assistentes pessoais como o Cortana (Microsoft), programas de reconhecimento facial que são muito utilizados em redes sociais (Facebook), pelos sistemas de segurança (Facewatch), com a finalidade de identificar pessoas através de imagens. Este tipo de aprendizado é utilizado para classificação de doenças, principalmente na área oftalmológica, para verificação por meio de imagens da retina ocular se o indivíduo possui glaucoma ou qualquer outra doença no âmbito oftalmológico (DeepMind). Esse tipo de aprendizado também é usado para redução de erro de diagnósticos cancerígenos por meio de imagens de linfonodos (Google). Programas de carros autônomos também fazem uso para a verificação de rotas mais curtas, lugares mais visitados, entre outros (Uber).

