



Inteligência Artificial
Prof. Luiz Antonio Ferraro Mathias

Conceitos básicos de Probabilidade

Para elucidar as Redes Bayesianas, primeiramente é necessária a compreensão da probabilidade, visto que a mesma é fundamentada nesses conceitos. Existem situações em que não é possível determinar o resultado de um evento, pois este apresenta variabilidade em sua ocorrência. Logo, para lidar com esses casos, é preciso atribuir uma medida que lide com a incerteza, a probabilidade. Segundo Faria R. (2014), há diversos conceitos possíveis para probabilidade como: a frequentista, clássica e bayesiana.

A teoria frequentista define que a probabilidade de ocorrência de um evento é a sua frequência relativa, ou seja, a quantidade de vezes que um evento aconteceu, repetido por diversas vezes até formar uma amostra, colocado sob condições similares. Com isso, é possível perceber que o resultado se aproxima de um número finito de repetições. Tomando como exemplo, um dado que é lançado 50 vezes, e observando que em 28 dos lançamentos resultaram no número 6, pode-se dizer que para esse dado, o número 6 ocorreu 0.56. No entanto, essa teoria possui alguns problemas como: a dificuldade de saber quantas vezes um experimento deve ser repetido para conseguir uma amostra significativa; definição de condições similares, pois isso poderia tirar o nível de incerteza do processo e em situações que não podem ser replicadas, não é possível obter a frequência relativa.

Conceitos básicos de Probabilidade

Já a teoria clássica estabelece que todos os possíveis resultados têm a mesma chance de ocorrência, ou seja, equiprováveis. Para isso, o cálculo é feito da seguinte forma: o número de elementos do evento sobre o número de resultados possíveis. Dando como exemplo, uma moeda e desejando-se saber qual a probabilidade de resultar em cara, sabendo que o número de caras é igual a 1 e o número de total de resultados é igual a 2 (cara ou coroa), logo cara e coroa tem 0.5 de chance de ocorrer. Essa teoria também possui uma restrição, pois não existe método para casos que não sejam equiprováveis.

Por fim, a teoria Bayesiana ou Subjetivista, inclusive o foco deste trabalho, é baseada na crença que uma pessoa tem sobre a ocorrência de um evento, o nível de crença é medido no intervalo de $[0,1]$, no qual 0 representa a incapacidade de ocorrência e 1 o indicativo de que certamente a crença ocorrerá. Nessa teoria, não existe uma probabilidade certa, mas sim a probabilidade adquirida pelo conhecimento de um indivíduo sobre uma ocorrência. Para ilustrar esta teoria, suponha que o conhecimento de uma pessoa A sobre a chance de ocorrência de um dado seja o número $6 = 0.5$ e, que outro indivíduo B que não viu o lançamento anterior, e a partir de seus conhecimentos diga que o número 6 tem a chance de ocorrência de 1. De acordo com Faria R. (2014), a teoria Bayesiana é criticada por diversos autores por alegarem que uma pessoa não está livre de preconceitos ao atribuir uma probabilidade e pelo fato de apresentar dificuldades quando conduzidas por mais de um pesquisador. No entanto são capazes de lidar com a incerteza e, também, podem atuar em conjunto com a frequência relativa e clássica.



Conceitos básicos de Probabilidade

Em resumo pode-se dizer que segundo Faria A. (2009), a Probabilidade é um campo que estuda a ocorrência de experimentos aleatórios. Experimentos aleatórios são acontecimentos que não se pode prever com certeza.

Para melhorar a compreensão dos assuntos que serão abordados, alguns conceitos de probabilidade são definidos a seguir:

- a) Espaço Amostral é o conjunto de todos os resultados possíveis de um experimento aleatório. Sendo definido pela letra Ω ou S .
- b) Evento é um subconjunto do espaço amostral. Sendo os eventos representados por letras maiúsculas e os elementos por minúsculas.
- c) Intersecção entre eventos são os elementos que estes têm em comum.
- d) Eventos disjuntos não possuem nenhum elemento em comum.
- e) Eventos são mutuamente exclusivos, se não podem ocorrer simultaneamente.



Axiomas da Probabilidade

Axiomas são premissas que se admite como plenamente verdadeiras sem a necessidade de constatação. São as propriedades que dão a base para a probabilidade, portanto uma probabilidade P que associa a um evento A do Ω em um número real $P(A)$, deve satisfazer os três axiomas:

I. Axioma: $P(A) \geq 0$: Todas as probabilidades devem ser positivas, ou seja, iguais ou maiores que 0.

II. Axioma: $P(\Omega) = 1$: A probabilidade do espaço amostral será sempre 1, isto é, a soma de todos os resultados possíveis, sempre deve resultar em 1.

III. Axioma: $A \cap B = \emptyset \rightarrow P(A \cup B) = P(A) + P(B)$: Se a intersecção com B resultar no conjunto vazio, ou seja, nenhum elemento em comum, isto quer dizer que a probabilidade de A união com B é igual a probabilidade de A mais a probabilidade de B .



Probabilidade Condicional

Axiomas são premissas que se admite como plenamente verdadeiras sem a necessidade de constatação. São as propriedades que dão a base para a probabilidade, portanto uma probabilidade P que associa a um evento A do Ω em um número real $P(A)$, deve satisfazer os três axiomas:

A probabilidade condicional define que um evento depende de outro para ocorrer. É representada por $P(B|A)$, que pode ser lida como: “a probabilidade do evento B acontecer dada a ocorrência do evento A ”. Logo B será calculado em função do espaço amostral reduzido de A .

$$P(B|A) = \frac{P(B \cap A)}{P(A)}$$



Probabilidade Condicional

A fórmula anterior é lida da seguinte maneira: a probabilidade dos eventos em comum de A e B em relação ao espaço amostral, sobre o espaço de A. Uma importante consequência da probabilidade condicional é o teorema da multiplicação (HAZZAN; IEZZI, 2004 apud GONÇALVES, 2008). Em situações, em que a probabilidade condicional é fácil de se calcular, é possível resolver a ocorrência simultânea de eventos pelo teorema da multiplicação. O teorema define que a probabilidade de dois eventos ocorrerem simultaneamente é a probabilidade do primeiro multiplicado pela probabilidade do segundo em relação ao primeiro. É representado pela fórmula a seguir:

$$P(A \cap B) = P(B|A) \cdot P(A)$$

Considere n eventos $B_1 \dots B_n \in \Omega$ e que são disjuntos, mas cuja união resultam no espaço amostral. Pode-se dizer que esses eventos formam uma partição.

Para calcular eventos diferentes que possuem partições, utilizamos o teorema da probabilidade total. Então para todo evento $A \in \Omega$:

$$P(A) = \sum_{j=1}^n P(B_j) \cdot P(A | B_j)$$



Independência

Um evento A independe de B, se a ocorrência de B não afeta a probabilidade de A.

$$P(A \cap B) = P(A) \cdot P(B)$$

Um evento X é condicionalmente independente de Y dado Z, se a distribuição que rege Z é independente de Y dado o valor de Z, que pode ser representado por:

$$P(X | Y \cap Z) = P(X|Z)$$



Variáveis Aleatórias

Conforme Silva (2016, p.13), uma variável aleatória (v.a) pode ser considerada um experimento e cada possível saída para um experimento é chamada de estado. Variáveis aleatórias normalmente são representadas por letras maiúsculas (A, B) e os elementos ou estados associados a ela são denotados por letras minúsculas (a, b). Além disso, Norvig e Russel (2004 apud Valentim, 2007) ainda as classificam em três categorias: variáveis aleatórias booleanas, variáveis aleatórias discretas e variáveis aleatórias contínuas.

As variáveis aleatórias booleanas só contêm dois valores, como por exemplo: a variável *TemGaragem* pode possuir os estados {*verdadeiro* ou *falso*}. Já as variáveis aleatórias discretas, ao contrário das booleanas, permitem múltiplos valores finitos, por exemplo, a variável *EstadoCivil* pode conter os valores {*Solteiro*, *Casado*, *Divorciado*, *Viúvo*}. Em relação, as variáveis aleatórias contínuas, estas podem classificar seus valores em um intervalo de [0,1] ou na linha real inteira.



Distribuição da Probabilidade Conjunta

Segundo Silva (2016), a distribuição da probabilidade conjunta é a probabilidade de ocorrência de duas ou mais variáveis aleatórias x_1, x_2, \dots, x_n ocorrerem juntas. Uma função de probabilidade conjunta necessariamente precisa satisfazer a seguinte propriedade, de acordo com Valentim (2016)

$$\sum P(X_1, X_1, \dots, X_n) = 1$$

Na equação 1.6 diz que os somatórios de todos os valores das variáveis devem resultar em 1. Russel (2004 apud Valentim, 2007) ainda as classificam em três categorias: variáveis aleatórias booleanas, variáveis aleatórias discretas e variáveis aleatórias contínuas.



Teoria de Bayes

O Teorema de Bayes é uma extensão do teorema da probabilidade total e da probabilidade condicional. Enquanto o segundo permite calcular um resultado dentre múltiplos eventos de cada partição a priori, ou seja, antes do evento acontecer, o Bayes **permite esses mesmos cálculos a partir de uma condição a posteriori, ou seja, depois que o evento a priori aconteceu.** A definição formal do Teorema de Bayes definida por (LIPSCHUTZ, 1993 apud GONÇALVES, 2008):

Teorema: Suponha $A_1, A_2, A_3 \dots A_n$ ser uma partição de S e B, um evento qualquer. Então para qualquer i

$$P(A_i|B) = \frac{P(B|A_i) \cdot P(A_i)}{P(B)} = \frac{P(B|A_i) \cdot P(A_i)}{\sum_i P(B|A_i) \cdot P(A_i)}$$



Teoria de Bayes

Uma interpretação do Teorema de Bayes, consiste em considerar os eventos A_i como “causas” do evento B, sendo atribuído probabilidades deste evento atuar na ocorrência de B. Esta probabilidade é calculada antes da realização do experimento, sendo designada como a probabilidade *a priori* de A_i . Após a realização do experimento, é conhecido que o evento B ocorreu, então a probabilidade *a priori* é revista por meio da fórmula de Bayes e então passa a atribuir aos eventos A_i , $i = 1, 2, \dots, n$ as probabilidades *a posteriori* $P(A_i|B)$, $i = 1, 2, \dots, n$ (CRAMÉR, 1955 apud GONÇALVES, 2008)(PAULINO; TURKMAN; MURTEIRA, 2003 apud GONÇALVES, 2008).



Teoria dos Grafos

A teoria dos grafos é utilizada no estudo de Redes Bayesianas para representar visualmente as relações de causa e consequência de variáveis e probabilidades. Conforme Faria, R. (2014), um grafo é um conteúdo matemático, que tem como principal capacidade a representação de conhecimento de maneira visual, e assim é amplamente utilizado em diversas aplicações.

Um grafo pode ser definido como um conjunto de elementos que possuem conexões entre si. Os elementos são denominados vértices, nós ou variáveis e suas conexões são chamadas de arestas ou arcos, tal estrutura pode ser compreendida na Figura 17. A sua representação matemática é definida como $G = (V, A)$, onde V são os vértices que podem ser representados por letras ou nomes dentro de um círculo, aresta ou retângulo e as arestas que são representadas por setas. A junção de nós e arcos apresentam a relação de dependência probabilística.



Conceito de Redes Bayesianas

As Redes Bayesianas (RB's) são uma representação qualitativa (teoria dos grafos) e quantitativa (probabilidade) de cenários que envolvam o processo decisório, prognóstico ou analítico, tendo em vista condições de incerteza, complexidade e falta de informações. De acordo com Charniak (1991), uma maneira de entender a aplicação de Redes Bayesianas é quando se tem conhecimento prévio da causa de um evento, mas ainda é insuficiente para a compreensão total do processo, e dessa forma é preciso modelar o problema probabilisticamente. Para melhor compreensão das Redes Bayesianas considere o exemplo de Yudkowsky (2003, apud Valentim, 2007, p.13).

1% das mulheres com mais de 40 anos que participam de exames de rotina são portadoras de câncer de mama. 80% das mulheres com câncer terão resultados positivos de mamografias. 9,6% das mulheres sem a doença também terão resultado positivo nas mamografias. Uma mulher dessa idade se depara com um resultado positivo de mamografia, qual a probabilidade dela portar câncer de mama?

Conceito de Redes Bayesianas

Para a construção de uma Rede Bayesiana com o exemplo dado acima, primeiramente é preciso identificar as variáveis de interesse. Como a situação foca na influência que o câncer tem sobre o resultado da mamografia, é notável que as variáveis são: *Câncer* e *Mamografia*. O próximo passo é definir as relações de causa e consequência do domínio em questão. A causa é o câncer e a consequência é a mamografia, uma vez que o fato de possuir ou não a doença é o fator que determina o resultado da mamografia, exceto para os casos em que há erros. Depois de identificado as variáveis de causa e consequência é necessário representá-las na rede como mostra abaixo:



Conceito de Redes Bayesianas

Nota-se que a estrutura de uma Rede Bayesiana é a mesma de um grafo acíclico dirigido (DAG), já que os arcos possuem direção e o nó inicial (*Câncer*) é diferente do nó final (*Mamografia*). Em relação a causalidade, esta é representada por um nó *Câncer* com um arco direcionado para o nó *Mamografia*, também sendo equivalente a dizer que *Câncer* é “pai” de *Mamografia*. Também há os estados dos nós *Câncer* e *Mamografia*, sendo respectivamente {presente, ausente} e {positiva e negativa}, no qual indica a probabilidade de ocorrência.

Quando a estrutura da rede é construída, a próxima etapa é a definição das probabilidades *a priori* e as probabilidades condicionais para as variáveis. As probabilidades das variáveis aleatórias *a priori* contêm os valores antes de qualquer ocorrência de outra variável, enquanto as condicionais apresentam a probabilidade de uma variável acontecer dado que outra ocorreu. A figura abaixo mostra as probabilidades *a priori* das variáveis *Câncer*.



Conceito de Redes Bayesianas

Na anterior pode-se interpretar assim como o exemplo, que a probabilidade *a priori* de uma mulher com mais de quarenta anos ter câncer é 1.0 e consequentemente, a probabilidade dela não ter é 99.0. A probabilidade *a priori* dos estados de mamografia é considerada 50.0 para resultado positivo da doença, tanto para resultado negativo, já que o exemplo não definiu uma probabilidade específica. É importante lembrar que, as probabilidades *a priori* e as condicionais, normalmente são definidas por especialistas na área, como o caso do domínio em questão que foram definidas por médicos, mas também podem ser definidas pela frequência relativa.

Assim que é finalizado a parametrização das probabilidades *a priori*, é necessário definir as probabilidades condicionais. Nesse caso, os estados da *Mamografia* {positiva, negativa}, dado que o estado de *Câncer* está presente ou ausente. A figura abaixo mostra o estado de *Câncer* estando presente e a Figura 20 apresenta a ausência da ocorrência de *Câncer*.

Câncer	
presente	100
ausente	0

Mamografia	
positiva	80.0
negativa	20.0



Conceito de Redes Bayesianas

Na figura anterior, pode-se notar que o nó *Câncer* contendo o estado presente influencia o estado do nó da *Mamografia* resultar em positivo em 80.0 dos casos e negativo em 20.0, coincidindo com as informações dadas no exemplo.

Já na figura abaixo, é perceptível que o estado da variável *Câncer* estar ausente influencia no estado da mamografia dar um resultado positivo de 9.60 e negativo de 90.4, equivalentes ao exemplo dado acima.

Câncer	
presente	0
ausente	100

Mamografia	
positiva	9.60
negativa	90.4



Conceito de Redes Bayesianas

De forma geral, uma Rede Bayesiana é uma combinação da Teoria dos Grafos, ou seja, a representação visual da Figura 1 e dos conceitos de Probabilidade e Estatística. Além disso, as redes bayesianas também podem ser chamadas de Rede de Crença, Rede Probabilística ou Causal. O objetivo da rede é apresentar as relações de causa e efeito das variáveis, juntamente com a disposição da probabilidade conjunta e, a partir disso possibilitar o procedimento de inferência. A rede também é capaz de por meio das relações de independência condicional, probabilidade condicional e independências incondicionais aliado com a representação visual das variáveis providas pelos grafos, compreender como um cenário atua e até mesmo, prever as ações de uma intervenção, a partir do cálculo de probabilidades *a priori*, ou seja, antes do evento acontecer e *a posteriori*, sendo depois do evento acontecer.



Construção de uma rede Bayesiana

Em primeiro lugar, deve-se selecionar as variáveis que são importantes no processo. Para isso, deve-se seguir alguns critérios Kjærulff e Madsen (2013 apud FÁRIA R, 2014): as variáveis devem conter valores mutuamente exclusivos, ou seja, que não podem ocorrer ao mesmo tempo; devem representar um conjunto único de eventos, sem a ocorrência de redundâncias; e devem ser muito bem definidas. Com as variáveis do modelo devidamente selecionadas, agora o problema é construir a estrutura da Rede Bayesiana, que é identificar entre quais variáveis terão arcos e qual direcionamento deve ser dado a cada um deles.

A construção pode ser feita através das relações de causa efeito identificadas pelo especialista da área a ser estudada, porém, caso não esteja disponível um especialista para auxiliar na construção da rede ou ele precise de um guia para ajudá-lo, é útil manter em mente os tipos de variáveis que podem surgir:

- **Variáveis problema:** São variáveis de interesse, das quais deseja-se calcular distribuições a posteriori dado os valores das variáveis de informação.
- **Variáveis de background:** São informações disponíveis antes da ocorrência do problema, com influência causal sobre as variáveis problema e variáveis de sintomas. São geralmente as variáveis 'raízes' das redes bayesianas.



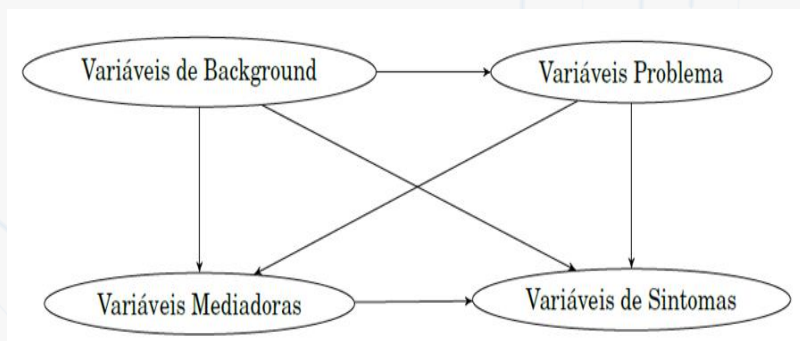
Construção de uma rede Bayesiana

- **Variáveis de sintomas:** São as consequências do problema, sendo disponíveis somente após sua ocorrência, ou seja, variáveis de sintomas são causadas pelas variáveis problema. Geralmente, as variáveis problema e de background são pais das variáveis de sintomas.
- **Variáveis mediadoras:** São variáveis não observáveis cujas probabilidades *a posteriori* não são de interesse imediato, mas que ajudam a manter as relações de independência corretas na rede. Estas variáveis geralmente são filhas de variáveis problema e de background e pais de variáveis de sintomas.

Os tipos de variáveis acima, propostos por Kjærulff e Madsen (2013 apud ARA-SOUZA, p.41), são uma forma de auxiliar a construção de Redes Bayesianas feitas manualmente, pois, após a identificação do tipo de uma variável, é muito mais fácil conectá-la às outras, já que geralmente o fluxo causal apresentado na figura a seguir é satisfeito.



Construção de uma rede Bayesiana



Um exemplo prático – seguro de automóveis

O seguro de automóveis tem como função a responsabilização pelos riscos e também pela indenização do veículo para o cliente no caso de colisão; acidentes; roubos e entre outros, em troca de um pagamento, denominado prêmio. Para que isso seja possível, a seguradora precisa estar regulamentada pela autarquia da Superintendência de Seguros Privados (SUSEP), que é responsável pelo controle e fiscalização do mercado de seguros no Brasil.

A identificação do grupo com riscos semelhantes é realizada por um questionário de avaliação de risco do segurado. Esta avaliação de risco é feita por intermédio do corretor e se resumem basicamente em perguntas referentes a idade; tempo de habilitação; sexo; região de circulação do veículo; obtenção de garagem ou estacionamento fechado para o automóvel; utilização do veículo e dispositivos de segurança. A partir disso e de dados estatísticos, a seguradora é capaz de identificar o perfil do segurado e os possíveis riscos que irá assumir, como por exemplo, um grupo com idade entre dezoito e vinte e cinco anos, do sexo masculino que apresenta muitos sinistros, ou seja, qualquer dano ao veículo, terá o valor do prêmio mais alto para todos com essas características.



Um exemplo prático – seguro de automóveis

De modo geral, existem diversos fatores que contribuem para a precificação do prêmio de seguro de automóveis: cobertura por colisão, idade do veículo, franquia, bônus e grau de periculosidade da cidade etc. Segue abaixo modelos de redes bayesianas aplicadas ao “case” citado.

